知识库（RAG）测试完整指南

一、知识库（RAG）测试概述

知识库一般基于 RAG（检索增强生成）架构：文档上传 → 解析切片 → 向量化入库 → 检索召回 → 大模型生成回答。测试覆盖**文档处理、向量库检索、问答效果、权限、性能、异常、兼容性**七大模块。

核心认知：**文件上传成功 ≠ 解析成功 ≠ 切片正确 ≠ 向量入库正确**。业务 UI 只展示上传状态，内部中间产物（解析文本、chunk 切片、向量）前端看不到，但必须测试；很多严重 bug 藏在内部中间环节，页面看不出异常，但问答答案全错。

1、文档导入与解析测试

1.1 文件格式支持

- 支持格式：pdf、docx、doc、txt、md、xlsx、csv 正常上传解析成功
- 不支持格式：exe、zip、图片等，给出明确报错，不崩溃
- 大文件上传：几十 MB PDF，上传进度、超时、断点提示
- 空文件、0 字节文件上传：校验拦截，提示无效文件
- 特殊命名：文件名含中文、空格、特殊符号、超长文件名，上传无乱码

1.2 文档解析能力

- PDF：扫描版图片 PDF（OCR 识别）、可复制文本 PDF；表格、页眉页脚、图片内文字识别
- Word：表格、多级标题、列表、换行、特殊符号解析不丢失内容
- Excel：单元格内容，多行多列表格解析完整
- 乱码文件：gbk 编码 txt 是否乱码；特殊字符、emoji 解析
- 文档重复上传：同一文件多次上传是否重复创建片段；是否支持覆盖更新

1.3 切片/分段（Chunk）测试

- 配置不同切片大小、重叠度：如 chunk_size=500、overlap=100，验证实际切片长度符合配置
- 边界：段落完整不强行切断句子；长段落、短段落切片效果
- 表格被切片：不要把表格拆得四分五裂
- 文档更新：修改原文档重新上传，旧向量片段是否清理，新切片生效
- 删除文档：对应向量片段彻底清除，问答不再召回该文档内容

2、向量库与检索召回测试（核心）

2.1 召回准确性

- 精准问题：问题原文完整出现在知识库，能够召回对应片段
- 同义改写：换说法、同义词，不使用原文语句，依然可以召回正确资料
- 模糊查询：部分关键词、简写、别名，验证召回
- 无关问题：提问知识库完全没有的内容，不召回无关片段，模型应回答没有相关信息（禁止编造幻觉）
- 多文档场景：多条文档都匹配问题，top-N 返回多条相关片段
- 召回数量参数：设置 top_k=3，校验最多返回 3 个片段

2.2 召回负向场景

- 问题关键词大量出现在知识库但语义无关：校验不要因关键词命中而错误召回
- 知识库存在相似冲突文档：两份文档对同一事实描述不一样，看优先召回哪一份，是否区分文档优先级
- 溯源引用：回答附带来源文档、片段序号，点击溯源可定位原始文档位置

3、问答生成效果测试（业务输出层）

1. 答案来源于知识库：只使用召回上下文，禁止模型调用自身训练知识编造内容（防幻觉）
2. 完整回答：问题答案分散在多个切片，模型整合多段信息输出完整答案
3. 答案精简：不要原样复制大段原文，做合理总结
4. 冲突内容：知识库两份文档信息矛盾，观察模型输出；是否提示信息冲突
5. 部分缺失：知识库只有部分信息，模型如实说明信息有限，不要补全脑补
6. 引用溯源：输出答案附带文档来源；关闭溯源则不展示来源
7. 多轮对话：上下文记忆，基于上一轮问答继续提问，依然参考知识库

4、权限测试（多租户场景）

- 知识库隔离：A 用户知识库内容，B 用户完全访问不到，问答不能跨库召回
- 角色权限：所有者/编辑者/只读者；只读用户不能上传删除文档
- 共享知识库：分享给指定用户后可查看问答；未分享用户不可访问
- 删除知识库：数据清除，无法再问答该库内容
- 知识库重命名：问答不受影响

5、性能测试

- 单知识库大量文档（上百份、上万切片）问答响应耗时
- 并发问答：多用户同时对同一知识库提问，响应、无超时无内存泄漏
- 导入耗时：大文档解析+切片+向量化耗时；有无进度提示
- 向量库压力：批量导入/批量删除大量文档，CPU/内存监控
- 超时场景：文档解析时间过长、问答 LLM 调用超时，友好错误提示

6、异常与边界测试

- 文档解析中途服务宕机：重启后状态为失败/待处理，不残留脏向量
- 向量数据库故障：给出友好报错，不能返回虚假答案
- 空白提问、全特殊符号提问：过滤无效输入
- 知识库为空时提问：提示暂无数据
- 超大提问（几千字）：系统截断或提示限制
- 文档状态：上传中、解析成功、解析失败状态展示正确，失败给出原因

7、配置项功能测试

- 切片大小、重叠度修改，新上传文档生效，旧文档是否重切
- Top-k 召回数量修改
- 相似度阈值：调小召回更多；调大严格过滤低相似度片段
- 幻觉抑制开关：开启严格模式禁止使用外部知识；关闭允许补充知识
- 引用来源开关
- 知识库 Prompt 模板自定义：验证按自定义模板输出

8、兼容性

- Web 端不同浏览器上传、问答
- 如有客户端：客户端知识库功能

典型缺陷分级参考

P1（阻断）

1. 提问知识库不存在内容，模型编造虚假答案（幻觉严重）
2. 删除文档/知识库，问答依然能召回已删除内容（向量没有清理）
3. A 租户可以召回 B 租户知识库数据（权限泄露）

4. 文件上传成功但完全解析不出内容，无报错
5. 向量库异常，返回错乱答案不报错

P2（严重）

1. 明明知识库有答案，检索召回不到，回答不知道
2. 召回大量无关文档片段
3. 溯源来源错误，指向错误文档
4. 切片把句子、表格暴力拆分，语义破坏

P3（一般）

1. 文件名中文乱码
2. 大文件上传无进度提示
3. UI 展示问题，功能可用

手工测试实战小技巧

1. 构造专门测试知识库的测试文档：包含正确答案、错误干扰信息、空白、表格
2. 两组文档：文档 A（正确事实）、文档 B（错误事实），用来测试冲突场景
3. 关闭大模型本身知识，专门测 RAG 召回：故意问知识库没有的冷门问题，看会不会瞎编
4. 打开溯源功能，每一个回答都核对召回的片段，判断答案是否来自召回片段

二、媒资知识库测试

媒资知识库（多模态媒资 RAG）常见于广电、OTT、视频平台、媒资管理系统。与普通文档知识库最大区别：**核心素材是视频、音频、图片，附带 ASR 语音转写、OCR 画面文字、关键帧、时间戳、媒资元数据**。

普通知识库：输入文件 → 文本切片 → 文本向量；媒资知识库：上传音视频/图片 → ASR/OCR/抽帧 → 生成文本片段+图像向量，每条召回结果绑定**媒资 ID、时间戳、片段起止秒数**，问答不仅返回文字答案，还返回对应视频片段点位、可跳转播放。

1、媒资入库与预处理层测试

1.1 音视频文件格式兼容

- 视频：mp4、mov、mkv、avi、flv、ts；音频：mp3、wav、aac、flac；图片：jpg/png/webp
- 损坏视频、无音频流视频、只有音频的文件、0 时长文件、超大时长视频（几小时纪录片）
- 多音轨、内外挂字幕 srt：ASR 转写 vs 外挂字幕，确认使用哪一路文本

- 扫描类视频：画面有文字，验证 OCR 识别进入知识库

1.2 AI 预处理能力（ASR/OCR/抽帧）

- ASR 语音转写：普通话、口音、背景音乐大、人声小；静音片段；多人对话；转写结果带时间戳，绑定正确的开始/结束秒数；静音长片段不生成大量空文本切片
- OCR 画面文字：画面字幕、PPT 投屏、滚动字幕，识别并关联对应帧时间戳
- 关键帧抽取：抽帧频率配置生效；镜头切换点抽帧；不要大量重复相似帧
- 切片逻辑：按时间切片，不是单纯字符切片；例如每 30s 切一个 chunk，携带时间区间
- 元数据绑定：每个向量片段绑定媒资 ID、媒资名称、startTime/endTime、分类标签
- 媒资更新：重新上传修改后的视频，旧向量清理，新数据生效
- 删除媒资：ASR 文本向量、图像向量全部清除，问答不能召回已删除内容（高频 P1）

2、检索召回测试（媒资特有）

媒资知识库有两套召回：**文本向量召回（ASR/OCR 文字）+ 图像向量召回（以文搜图/以图搜片段）**。

- 文本提问命中视频语音内容：召回对应片段，返回正确时间戳，跳转播放定位准确
- 语义提问（不使用视频原话）：依然召回正确视频片段
- 跨模态检索：用文字描述画面内容，召回对应视频帧/图片
- 时间边界：答案分布在视频多个时间片段，召回多条带不同时间区间的片段
- 冲突场景：同一媒资不同时间段说法冲突；不同媒资信息冲突
- 溯源校验：返回媒资名称、片段起止时间、关键帧预览；点击溯源跳转，播放器精准跳转对应秒数，不能偏移
- 过滤检索：基于媒资元数据过滤（分类、时间范围）做知识库问答过滤
- 负向：媒资没有相关内容，模型禁止编造，返回无相关信息

3、问答生成业务层

- 答案来源只能基于 ASR/OCR 文本、图片理解内容，禁止模型自身知识编造
- 答案分散在多个时间切片：模型整合多个时间段内容输出完整答案
- 输出媒资片段引用：回答中展示片段时间点位；关闭溯源开关则不展示
- 多轮对话：基于上一轮提到的视频片段继续追问，依旧绑定媒资上下文
- 边界：媒资只有部分片段有答案，如实说明信息范围，不要脑补
- 超长媒资：几小时长视频，问答不会因素材过长超时、截断

4、媒资知识库权限（多租户）

- 媒资隔离：A 租户媒资，B 租户知识库问答完全检索不到
- 媒资本身权限继承：媒资设置为私有，加入知识库后无权限用户问答不可召回
- 媒资删除/归档：归档媒资是否还参与知识库检索，匹配产品设计
- 媒资授权共享：媒资共享给团队，知识库问答可正常召回

5、性能与压力测试

- 批量导入大量音视频：统计 ASR+OCR+抽帧+向量化耗时，任务进度展示，失败任务状态清晰
- 大量媒资入库后问答响应；并发问答
- 大视频预处理中途服务宕机：重启任务状态为待处理/失败，不残留脏向量
- 存储压力：大量视频产生海量文本向量+图像向量，监控向量库内存
- 超时场景：ASR/OCR 预处理超时、LLM 问答超时，友好报错，不返回虚假答案

6、配置项专项测试

- 切片时长配置：如每 20s 切片、重叠 5s，验证新媒资切片时间区间符合配置
- 抽帧频率配置生效
- top-k、相似度阈值
- 是否开启图像向量检索开关：关闭后只走 ASR 文本检索
- 溯源开关：是否返回时间戳、关键帧
- prompt 自定义模板控制答案输出格式

7、异常边界

- 视频无有效人声：ASR 输出空文本，知识库没有该视频知识
- 视频只有画面文字无语音：依赖 OCR 产出知识；OCR 失败则无知识库内容
- 媒资预处理失败：知识库状态标记失败，不生成无效向量
- 空媒资知识库提问：提示暂无媒资知识
- 时间戳越界：返回的 startTime 大于视频总时长，属于严重 bug
- 媒资代理流：溯源跳转播放代理视频，而不是原始高清文件

媒资知识库缺陷分级

P1 阻断

1. 删除媒资，问答依然召回该视频 ASR 内容（向量没有清理）
2. 召回返回时间戳错误，跳转播放位置偏差巨大

3. A 租户能够检索 B 租户私有媒资知识库内容
4. ASR/OCR 识别成功入库，但问答完全召回不到内容
5. 媒资不存在该信息，模型编造答案

P2 严重

1. 明明媒资有答案，召回无关视频片段
2. 溯源媒资正确，但时间戳点位错误
3. 切片把连续语义拆碎，跨时间片段语义断裂
4. 以文搜图/画面检索完全失效

P3 一般

1. 预处理进度展示异常，但最终结果正确
2. 关键帧预览图加载失败，问答文字结果正常

三、问题集如何准备

问题集 = 测试用的提问样本库，用来批量/手工验证**召回准确率、问答质量、幻觉、边界、溯源**。核心依据：需求规格、业务场景、知识库数据特征、风险点、等价类+错误推测法。

1、准备问题集的 5 大依据

依据 1：产品需求文档（PRD）

- 知识库支持哪些能力：同义、跨模态、元数据过滤、时间片段溯源、多轮、幻觉抑制开关
- 业务目标：素材定位？知识问答？剪辑点位查找？（决定问题侧重）
- 约束：没有知识库内容时的输出话术；是否允许大模型补充外部知识；溯源是否强制返回

依据 2：知识库内的样本数据（最重要）

- 知识库内真实存在的事实、台词、画面信息 → 设计正向命中问题
- 知识库部分存在：信息零散、分散在多个时间切片、多个媒资
- 知识库互相冲突：两份媒资描述同一事实说法不一样
- 知识库完全不存在的信息：专门用来测幻觉（必做）
- 媒资本身特征：口音 ASR、滚动 OCR 字幕、长纪录片、多片段、静音片段、多媒资

依据 3：测试点/风险点

问题集要覆盖全部风险：召回风险（关键词命中但语义无关、同义改写、模糊简写）；媒资特有风险（跨时间片段、时间戳准确性、跨模态图文检索）；权限风险（不同角色视角下同一套问题）；异常

风险（空输入、超长输入、特殊符号）。

依据 4：等价类划分 + 边界值

- 有效等价类：知识库存在、完整信息、部分信息
- 无效等价类：知识库无信息、语义模糊、无关问题
- 边界：答案跨多个 chunk、跨多个媒资、跨多个时间片段；刚好在切片分割点位置的内容

依据 5：真实用户业务场景

- 业务人员：“帮我找出所有提到 XX 政策的视频片段”
- 剪辑人员：“哪一段采访提到这个观点，给我时间点”
- 普通查询：直接摘抄台词；口语化提问；简写提问

2、问题集分类（媒资知识库专用）

类别 1：精准命中问题（正向基础）

验证基础召回可用，原文台词、原文文本找得到。示例：“视频中提到 XX 项目的目标是什么？”校验点：召回对应媒资、时间戳正确、答案正确、溯源匹配。

类别 2：同义/改写提问（语义召回重点）

换表达方式，验证向量语义检索而非简单关键词匹配。例：视频原话“项目周期为 12 个月”，原问题“项目周期多久”，改写问题“这个项目要花多长时间完成？”

类别 3：信息分散场景（多切片/多媒资）

答案不在同一 chunk、同一视频，需合并多个片段信息。示例：“汇总所有视频中提到 XX 的观点。”校验：召回多条片段、多个时间戳、模型整合输出完整答案。

类别 4：知识库不存在信息（幻觉专项，最高优先级）

检验是否瞎编。示例：“请介绍 XX（知识库完全没有的事件）”。预期输出“未查询到相关信息”，禁止编造事实。注意：出题前确认知识库内确实没有。

类别 5：冲突信息问题

多条媒资对同一事实说法不一致时模型表现。示例：“XX 的参数是多少？”校验：同时给出两方信息？还是取优先级高的媒资？不能只输出其中一个当作唯一真相。

类别 6：异常与边界问题集合

- 空提问、全空格、特殊符号
- 超长提问（上千字符）

- 非常模糊的问题，缺少上下文
- 只问时间点：几分几秒讲了什么

类别 7：跨模态问题集

文字描述画面内容，找出对应视频片段；校验召回对应关键帧+媒资+时间戳。

类别 8：多轮对话问题集

Q1“哪个视频介绍 A 方案？”→ Q2“那里面提到的风险有哪些？”（上下文依赖上一轮媒资）。校验保持媒资上下文。

类别 9：元数据过滤问题集

如“在【访谈类】媒资里面找关于 XX 的内容。”校验只召回指定分类下媒资。

3、问题集产出完整流程

1. 先准备测试素材集（媒资+文档）：正向素材、冲突素材、部分信息素材、不含目标信息的素材
2. 素材导入媒资知识库，等待 ASR/OCR/切片/向量化全部处理完成
3. 阅读素材内容，梳理知识库里面的事实点，基于素材事实编写问题集
4. 按 9 个类别分类，每个类别设计若干条
5. 编写每条问题的预期结果：预期召回哪些媒资、预期时间戳范围、预期答案要点、不存在场景预期返回无相关信息
6. 执行测试，记录实际结果；对比预期 vs 实际，发现缺陷
7. 回归测试：问题集可复用，版本迭代直接跑一遍

> 常见踩坑：先写问题再上传素材，知识库根本没有对应信息，测试完全无效。顺序不能颠倒：素材先行，再出问题集。

4、问题集规模建议

- 手工测试：每个分类 5-15 条，总共 50-100 条
- 自动化评测（RAG 评测）：几百条，搭配 RAGAS 等评测集，需标注 question、ground_truth、contexts

5、问题集文档模板

用例ID	问题描述	问题类型	知识库是否存在该信息	预期召回媒资	预期时间戳	预期输出要点

Q-001	xxx	精准命中	是	媒资A	00:10-00:30	xxx
Q-002	xxx	幻觉测试	否	无	无	返回无相关信息

6、评测维度（跑完问题集统计指标）

- 召回率：应该召回的片段有没有召回
- 精确率：召回出来的片段是不是真的相关
- 幻觉率：知识库无信息，模型编造答案占比
- 时间戳准确率（媒资知识库特有）
- 溯源正确性

四、银行项目问题集准备

银行知识库分两类：1）文档类知识库：制度文件、业务规程、风控规则、产品手册、监管要求、FAQ、合同模板；2）媒资知识库（较少）：培训音视频、业务讲解录像、客服录音 ASR 转写。

银行属于强监管业务，问题集不能随便编造，有强业务合规、风控、数据安全要求。

1、编制依据

依据 1：业务 PRD 与银行业务需求

- 知识库定位：内部员工问答助手 / 客服辅助知识库 / 客户侧智能问答
- 核心约束：严禁输出知识库以外的业务结论（防幻觉最高优先级）；答案必须溯源到具体制度文件、条款；敏感数据管控；监管合规；密级权限

依据 2：知识库真实导入的资料（最重要）

顺序：先导入银行真实/脱敏测试文档，再编写问题集，禁止先写问题再找文档。注意知识库内的：信贷规则、开户要求、理财产品规则、反洗钱要求、手续费标准、挂失流程、监管文件；信息分散；新旧版本制度冲突（旧版未下架，高频真实场景）；完全不存在的业务（测幻觉）；文档特征（扫描件制度、费率表、红头文件、修订版附件）。

依据 3：风险点与测试点（银行重点）

- 幻觉风险：模型编造费率、贷款条件、风控规则，属重大生产事故 P0
- 权限泄露：低权限角色召回密级文档内容
- 新旧制度混淆：召回已废止旧制度给出错误业务结论
- 表格类规则：费率、限额、办理条件表格解析切片错误
- 溯源准确性：回答引用错误制度条款

- 敏感输入：身份证、卡号、敏感业务提问

依据 4：等价类 + 真实用户提问样本

优先收集真实业务人员提问样本：柜员、风控、客服、后台运营日常真实查询话术，再补充等价类、边界。

依据 5：监管与安全要求

- 不能输出客户隐私
- 不能输出未对外公开的内部风控细则
- 输出话术不能误导金融消费者

2、银行知识库问题集分类（含示例）

1、精准原文命中类（正向基础）

示例：个人一类银行卡开户需要哪些材料？个人转账单日限额是多少？理财产品风险等级 R2 适合什么样的客户？校验：召回正确制度文档+条款溯源，答案与制度原文一致。

2、同义改写、口语化业务提问（P1）

制度原文“一类户非柜面交易单日累计限额 5 万元”，口语问题“我一类卡手机银行一天最多能转出去多少钱？”校验正确召回对应条款。

3、信息分散，跨文档/跨章节问题

示例：“汇总个人信用卡挂失后的全部处理流程以及手续费。”校验召回全部相关文档片段，信息不遗漏。

4、新旧版本制度冲突场景（银行特有 P1）

测试库故意导入新版制度 V2（生效）、旧版制度 V1（已废止）。示例：“XX 业务最新办理要求是什么？”校验：优先召回生效新版本；提示存在旧版本已废止；不能拿作废制度当答案。

5、知识库不存在业务场景（幻觉专项 P0）

示例：“我行 XX 未上线的贷款产品申请条件是什么？”预期返回“未查询到相关信息”，绝对不能编造业务规则、费率、办理条件。

6、表格类规则专项测试

银行大量表格（手续费表、风险等级表、限额表）。示例：“查询不同风险等级理财产品的适合客户范围。”校验表格解析切片完整，数值、费率不能出错。

7、密级与权限维度问题集（安全 P1）

同一套问题使用不同权限账号分别执行。素材：公开制度、内部资料、机密风控文档。校验：低权限角色查询不到机密内容；高权限正常召回；禁止越权返回密级资料。

8、多轮对话业务问题集

Q1“个人二类卡限额是多少？”→ Q2“那如果我要调高限额该怎么办理？”校验继承上下文，继续召回相关制度。

9、边界与异常输入问题集

超长业务提问；模糊提问（“银行卡有什么限制？”）；特殊符号；空输入。

10、负面/误导类提问

示例：“怎么绕过转账限额？”校验：知识库没有绕过规则，不能编造违规操作指引。

11、媒资扩展（录音/培训视频媒资知识库）

“找哪一段培训录像讲解信用卡逾期处理规则？”校验召回媒资+时间戳，溯源 ASR 文本。

3、银行知识库问题集模板

用例ID	问题描述	问题类型	知识库是否存在该信息	涉及密级	预期召回文档	预期输出要点	重点校验项
B-001	个人一类卡手机银行转账限额多少	同义口语提问	是	公开	《个人结算账户管理规范V2.pdf》	输出限额数值	溯源条款正确，不取旧制度
B-002	我行 XX 虚拟贷款产品申请条件	幻觉测试	否	-	无	返回未查询到相关信息	禁止编造条件、费率 P0
B-003	XX 业务最新办理要求	新旧制度冲突	是	内部	生效V2制度	优先新版本，提示旧版废止	不能输出废止规则

4、银行项目特别注意事项

1. 绝对不要使用真实生产客户数据，所有测试文档使用脱敏样本
2. 幻觉问题集是 P0 级别缺陷：模型编造金融业务规则等同于线上重大事故
3. 重点关注作废/旧版制度：很多项目只新增不删除，极易召回旧规则
4. 表格解析：费率、限额表格切片极易切坏，高频 bug

5. 权限问题集必须分角色跑同一套问题，不能只用管理员账号（管理员全部可见，测不出权限泄露）
6. 所有回答必须支持溯源到具体文档名称+条款位置
7. 不能直接拿网上公开金融问答当问题集，必须基于导入的测试文档出题

5、规模建议

- 手工版本：80-120 条，覆盖正向、幻觉、新旧制度、权限、表格、多轮
- 自动化评测：几百条，重点看幻觉率、召回准确率、版本正确性、权限通过率

五、华为海思知识库项目

海思属于**半导体芯片研发内部垂域知识库**，面向 IC 设计、SDK、媒体芯片、NPU、ISP、驱动、FAE 技术支持团队，查询芯片手册、寄存器、SDK 文档、勘误表、FAQ、原理图、调试笔记、培训音视频。属于**强技术密级、强版本管控、强权限隔离**的企业 RAG 知识库。

1、项目业务背景

芯片产品线繁多（Hi35xx 媒体芯片、ISP、NPU、MCU、汽车芯片等），文档体量巨大：数据手册 DS、参考手册 RM、寄存器手册、SDK 开发文档、勘误 errata、FAE 问题案例、调试报告、培训音视频、原理图、Release Note。痛点：文档分散、手册动辄上千页、芯片多版本与勘误绑定、新员工与 FAE 定位问题耗时。目标：工程师自然语言提问，直接返回寄存器、参数、限制条件、勘误说明，溯源到手册章节+文档版本。

2、整体架构链路

原始资料（PDF 手册、docx、wiki 导出、errata 勘误、录音培训视频）→ 文档预处理（解析 PDF/表格/代码块、识别寄存器表格、处理勘误标记；音视频做 ASR 抽帧）→ 切片（不按固定字符粗暴切分，优先保证寄存器表格、代码片段、勘误条目完整；打上元数据：芯片型号、硬件版本、文档版本、密级、生效时间、模块分类）→ 向量化入库（向量库+结构化元数据索引）→ 混合检索（向量语义检索+元数据过滤）→ LLM 生成回答（强制溯源）→ 权限层（密级控制、产品线隔离）。

关键差异：普通 RAG 只靠向量；海思芯片知识库是混合检索，元数据过滤权重非常高。问 Hi3516 必须优先过滤出 Hi3516 相关文档，不能召回 Hi3518 资料。

3、核心业务特性

1. 芯片型号与硬件版本强绑定：同一问题不同芯片版本答案不一样；勘误只针对特定硅版本
2. 表格、寄存器、代码片段优先完整保护：切碎直接导致答案错误（P1）
3. 勘误文档优先级高于原版手册：输出需提示勘误修正点
4. 密级严格隔离：不同产品线互相隔离，机密手册普通 FAE 账号不可检索
5. 强制溯源：文档名称、文档版本、芯片型号、章节；媒资附带时间戳

6. 媒资知识库扩展：培训录像、FAE 复盘录音 ASR 转写入库
7. 旧版本/废止文档管控：默认返回当前生效版本文档，可手动勾选历史版本

4、测试点（海思特有）

1、文档入库解析

- PDF 芯片手册：寄存器表格、位域说明、代码片段、原理图注释解析完整
- errata 勘误文档入库：条目完整，元数据绑定对应芯片硅版本
- 多版本文档：Hi3516 V100 与 V200 手册导入，切片打上正确型号、版本元数据
- 代码块解析：SDK 样例代码不被切碎
- 删除归档文档：向量和元数据全部清理

2、检索召回（最核心风险点）

- 指定芯片型号提问只召回对应资料，不混入其他芯片参数
- 勘误优先：原版写 A，勘误修正为 B；输出 B 并提示勘误来源
- 硬件版本边界：勘误只针对 V1 硅片，V2 无此 bug；提问区分硅版本
- 同义技术提问：工程师口语提问，语义召回
- 跨文档聚合：限制分散在手册+勘误+SDK note，聚合全部信息
- 负向：知识库没有该芯片参数，禁止编造（幻觉 P0）

3、问答生成业务层

- 输出溯源：文档名称、文档版本、芯片型号、章节号完整
- 区分生效版本：旧归档文档默认不参与召回
- 表格数据输出：寄存器位域、参数表准确，数值、掩码不能出错
- 媒资场景：培训录像提问调试问题，返回 ASR 片段+时间戳

4、权限密级测试

- 产品线隔离：A 芯片产品线工程师不能检索 B 芯片机密文档
- 密级：普通 FAE 账号不能检索核心机密寄存器内部文档；高权限研发账号正常访问
- 归档文档权限逻辑

5、性能与异常

- 单手册几千页 PDF 批量入库解析切片耗时；大量寄存器表格入库稳定性
- 并发问答，混合检索响应耗时

- 预处理中途宕机，无脏向量残留

6、配置项

- 切片大小、重叠度；保护表格/代码块不切割开关
- 元数据过滤权重配置；勘误文档优先级配置
- top-k、相似度阈值；幻觉抑制开关；溯源开关

5、问题集如何准备（海思重点）

编制依据

- PRD：元数据过滤规则、勘误优先级、密级权限、归档文档策略
- 导入知识库的真实芯片手册、勘误 errata、SDK note，先导入素材再写问题集
- 业务真实场景：研发、FAE 真实高频问题
- 风险点：芯片型号混淆、勘误未生效、表格切碎、幻觉编造寄存器参数、权限泄露

问题集分类（海思特有样例）

1. 精准原文命中：Q“Hi3516 V200 VI 模块支持最大分辨率？”
2. 技术口语同义改写：手册原文“HI_MPI_VI_SetChnAttr 设置通道输出分辨率最大 4096×2160”，口语问题“海思 3516 VI 通道输出最大能到多少像素？”
3. 勘误 errata 专项（P1）：Q“Hi3516 V100 芯片 VO 模块存在什么已知 bug？”预期召回 errata，注明仅 V100 存在、V20 已修复
4. 多芯片版本区分：同一问题分别问 V100、V200，返回各自参数，不能串版本
5. 信息分散：手册+勘误+SDK note 聚合
6. 幻觉专项 P0：Q“Hi3516 有没有 XXX 寄存器？”禁止编造寄存器地址、掩码
7. 表格寄存器专项：位域、掩码、复位值全部正确
8. 权限维度：同一套问题分别用 FAE 账号、研发账号执行
9. 归档旧文档场景：默认提问不召回归档退市芯片文档；手动勾选历史版本才返回
10. 媒资问题集：哪段培训视频讲解 Hi3516 ISP 噪点调试

问题集模板

用例ID	问题描述	问题类型	知识库是否存在信息	指定芯片型号/版本	预期召回文档	预期输出要点	重点校验项

H-001	Hi3516 V200 VI 最大输出分辨率	精准提问	是	Hi3516 V200	Hi3516V200 RM 手册 V1.2	输出 4096×2160	不能混入 V100 参数，溯源正确
H-002	Hi3516 V100 VO 模块已知 bug	勘误专项	是	Hi3516 V100	errata V1.1	输出 bug 说明，注明 V20 修复	勘误优先级高于原版手册 P1
H-003	Hi3516 寄存器 XXX 功能	幻觉测试	否	Hi3516 V200	无	未查询到相关信息	禁止编造寄存器 P0

6、海思知识库高频坑点

1. 跨芯片版本串数据：问 Hi3516 召回 Hi3518 参数，高频 P1；根源是元数据过滤失效
2. 切片把寄存器表格、勘误条目切碎，表格字段丢失
3. 勘误文档入库但优先级低于原版手册，输出错误参数
4. 归档退市文档没有过滤，拿废弃芯片资料当答案
5. 幻觉编造寄存器地址、掩码、硬件参数（严重事故）
6. 密级权限失效，低权限账号拿到机密芯片内部手册
7. 溯源信息缺失：看不到文档版本、芯片型号，工程师无法确认答案可靠性

六、核心疑问解答：解析、切片、向量化要测到什么程度

核心疑问：业务层只看到“文件上传成功”，需要测解析后的内容吗？向量化切片逻辑之类的要测吗？

结论：**上传成功 ≠ 解析成功、解析成功 ≠ 切片正确、切片完成 ≠ 向量入库正确**。业务 UI 只展示上传状态，内部中间产物前端看不到，但必须测试。分层测试策略：黑盒为主，必要时借助后台查看中间产物做灰盒验证，不需要解析向量浮点数，但要校验切片文本、chunk 元数据。

1、各环节测试深度

1、文件上传（UI 可见）

测格式、大小、文件名、空文件、损坏文件、并发上传、断点。这一层只是传到服务器，不代表内容处理没问题。

2、文档解析层（重点，业务页面看不到解析文本）

UI 状态显示解析成功，但页面不会展示完整解析文本。风险：上传 PDF 显示解析成功但表格丢失、乱码、OCR 没识别出来，页面状态依旧是“解析成功”，后续问答答不出来。

需要测解析后的内容，不能只看状态码。测试手段：平台提供预览解析文本则直接核对；没有预览则去后台查看解析产出的原始文本；没有后台权限则靠问答+溯源反向校验（溯源出来的上下文就是解析后的文本）。

校验点：正文、表格、列表、标题、代码块、费率表是否完整；扫描件 OCR 结果；乱码、特殊符号丢失；页眉页脚是否错误混入正文；部分损坏文件不能返回“解析成功”但内容为空。

3、切片 Chunk 层（业务 UI 完全看不见）

切片是 RAG 质量的根源：把一句话拦腰切断、把表格切碎，后续召回再完美答案也错。

校验维度：参数配置生效（chunk_size、overlap）；语义完整性（最高优先级，不在句子/表格/代码块中间切断）；特殊对象保护（表格、代码块、勘误条目完整放同一 chunk）；重叠度生效；元数据绑定（芯片型号、版本、时间戳、文档 ID）；更新文档旧 chunk 删除；删除文档全部 chunk 清除。

验证方式：有后台直接导出 chunk 列表核对；无后台依靠溯源上下文（问答返回的 context 就是切片原文）看是否被暴力切割。

4、向量化层（向量是浮点数数组，人读不了）

不需要校验向量浮点数值本身，但要测向量化动作的结果现象：chunk 文本是否成功送入向量库（有没有 chunk 解析出来但没生成向量）；删除文档后关联向量是否全部清理（高频 P1）；更新文档旧向量删除、生成新向量；向量库故障时友好报错而非编造答案。通过上层召回行为间接验证向量化是否生效；灰盒可后台看向量库数量统计。

5、检索召回层

不只测能不能召回，还要测：纯向量召回；混合检索（向量+元数据过滤）；top-k、相似度阈值配置生效；精准、同义、部分匹配；关键词命中但语义无关的负向用例；多文档、多 chunk 召回；冲突信息；溯源 context 正确性。

6、LLM 业务问答层（输出层）

幻觉抑制；基于召回上下文作答；多轮对话；溯源输出；冲突内容呈现；信息不全如实说明。

7、配置项测试

切片大小、重叠度、top-k、相似度阈值、幻觉开关、溯源开关、勘误优先级。坑：界面修改配置只保存 UI，实际处理文档仍用旧参数。

8、权限与多租户与数据隔离

知识库隔离、文档隔离、chunk/向量不能跨租户泄露；不同角色权限。底层是 chunk 和向量带权限元数据；不能只测前端页面隐藏文档，底层向量还能被检索召回。

9、异常流程

上传中途断网、服务重启、解析/切片/向量化过程服务宕机；大文档超时；部分失败（多文件导入一个失败不影响其他文档）；失败任务不产生脏 chunk、脏向量。

10、性能

批量文档导入耗时；批量删除；并发问答；向量库压力。

2、没有后台权限怎么测

拿不到数据库、向量库后台时，用**溯源上下文当作观测窗口**。问答返回的溯源上下文（context）就是切片后的原始 chunk 文本。可以反向验证：解析结果（context 文本与源文档是否一致，有没有丢表格、乱码）；切片效果（context 文本是否完整语义）；chunk 是否正确入库（该召回的出现在 context，不该出现的——已删除文档——不出现）。

缺点：只能看到被召回的 chunk，看不到从未被召回的。补充手段：构造问题尽可能触发不同位置 chunk 召回，覆盖文档开头、中间、表格、末尾。

3、黑盒/灰盒对照表

模块	是否 UI 可见	测试手段	是否要深入内部
文件上传	可见	黑盒	测文件、状态即可
文档解析文本	不可见	溯源/后台查看解析文本	要校验解析后的内容，不只看“解析成功”状态
Chunk 切片	不可见	溯源 context/后台导出 chunk	校验切片文本完整性、元数据；不校验算法内部
向量化向量数值	完全不可见	间接通过召回行为验证	不校验向量浮点数；校验向量入库、删除、更新行为
检索召回	部分可见（溯源）	黑盒+溯源	完整测试召回逻辑
LLM 问答输出	可见	黑盒问题集	完整业务测试

4、现实踩坑总结

错误做法：只看页面“上传成功、处理完成”就认为文档没问题；只测问答好坏忽略解析、切片。正确思路：解析、切片、向量化属于内部处理流水线，每一步输出质量直接决定问答质量；有后台灰盒抽查中间产物；无后台充分利用溯源上下文反向验证；向量浮点数不用测，但向量的入库、更新、删除、隔离行为必须测。

七、溯源上下文（context）详解

context = 检索阶段捞出来的一批 chunk 切片集合，就是真正拼到 Prompt 里送给大模型的原始片段数组。RAG 流程：用户提问 → 向量库检索 → 返回若干 chunk（切片文本 page_content + 元数据 metadata：文档名、chunk_id、页码、芯片型号、时间戳等）→ 组装成 context 塞给大模型 → 大模型只基于这堆 context 生成答案。大模型看到的全部外部资料就是这个 context；答案对不对、幻觉不幻觉，根源就在 context。

1、两种 context

- 检索原始 context（retrieved_context）：向量库召回的 top-n 全部候选切片（未过滤、未裁剪）
- 送入 LLM 最终 context：经过过滤、去重、rerank 重排、token 裁剪之后真正发给大模型的部分，测试重点看这个

2、获取 context 的 3 种途径

方式 1：调用问答接口，开启溯源开关，接口返回 context（最推荐）

企业知识库接口一般有开关（ref_enable=true / return_source_documents:true），开启后响应体返回专门字段：source_documents / references / rag_log / retrieve_list。数组每一项：

代码块

```
{
  "content": "切片原始文本（就是chunk）",
  "metadata": {
    "source": "xxx.pdf",
    "chunk_id": "ch001",
    "page": 5,
    "chip": "Hi3516V200"
  },
  "score": 0.86
}
```

直接用 Postman/Jmeter 调用问答接口，打开溯源参数，接口直接吐出全部召回切片文本+元数据。这是灰盒测试手段，不需要登录向量数据库，不需要后台权限。可以拿返回的 content 与源文档人工对比：校验解析是否丢内容、切片有没有把表格拦腰切断、元数据是否正确。

注意：部分流式 SSE 接口，context 不会混在 answer 流里面，会单独在一个 event 事件返回（例如 event-references、event-rag_log），要单独解析这个事件，不要只看 answer 文本流。

方式 2：前端页面 UI 的溯源引用（能力有限）

页面上点开“查看引用/来源片段”，UI 展示部分片段。缺点：UI 常做摘要截断，展示的不是完整 chunk 原文；有些系统前端只展示文档名页码，不展示完整切片文本；看不到没有被大模型“引用”但被检索出来送入 prompt 的切片。只能做辅助参考，优先用接口拿 context。

方式 3：后台直接导出 chunk 数据（完全灰盒，需要开发给权限）

直接访问文档处理服务/向量库，导出每个文档对应的全部 chunk 列表（chunk_id、page_content、metadata）。优势：可以看到该文档全部切片，不光是被本次问答召回的那几条，适合专项测试解析与切片质量。缺点：测试人员一般拿不到生产环境权限，测试环境可申请。

3、回到核心问题：解析、切片、向量化测到什么程度

1、文档解析测试

UI 只显示“解析成功”毫无说服力。最优：接口拿到 context 里的 content 对比源文档，核对表格、列表、代码块、特殊字符、扫描 PDF OCR 内容有没有丢失。如果接口返回的 context 里文本就丢了表格，说明解析层 bug，还没走到检索环节。

2、切片 Chunk 测试

有后台：导出全部 chunk 校验实际大小、重叠度、表格/代码块没有被切断、元数据绑定正确。只有接口权限：只能看到本次问答命中的 chunk。局限：有些 chunk 构造的问题没有触发召回，接口看不到。弥补：构造多组问题覆盖文档开头、中间、表格位置、末尾段落。典型坑：寄存器表格切成 2 个 chunk，提问命中上半部分关键词只召回半个表格，接口返回 context 只能看到残缺的一半，就能发现切片缺陷。

3、向量化（Embedding）

不去校验向量浮点数数组。通过 context 间接验证行为：文档处理完成，合理问题对应 chunk 应出现在接口返回 context 列表；删除文档后再次提问，该文档所有 chunk 不能再出现在 context 数组（P1 缺陷：向量残留）；更新文档后旧 chunk 不出现、新切片出现在 context。如果解析出来文本没问题，但无论怎么提问该 chunk 永远不会出现在 context，说明向量化入库失败。

4、面试总结话术

> 溯源上下文 context 就是 RAG 检索返回的切片 chunk 数组，是真正传给大模型生成答案的原始材料。测试优先通过调用问答接口，开启溯源参数，从接口响应拿到完整的 source_documents 数组，拿到切片原文与元数据，不需要直连向量库。借助接口返回的 context，可以反向校验文档解析是否丢失内容、切片是否暴力切割表格语义、元数据是否绑定正确；接口只能看到本次问答召回的 chunk，如果要完整校验一份文档全部切片，则需要后台导出全部 chunk。向量浮点数本身不需要校验，但通过 context 的出现/消失行为，验证向量新增、更新、删除逻辑是否正常。

5、现实项目踩坑点

1. 有些产品溯源开关只控制前端页面显不显示引用，接口不会返回完整 chunk 原文，只返回文档名页码。这种情况测试要提需求：问答接口必须输出完整 retrieved_context，否则 RAG 测试无法开展
2. SSE 流式接口不要只拼接 answer 文本，rag 日志、reference 事件是独立事件，漏解析就拿不到 context
3. 区分检索召回出来的候选 context VS 最终送入 LLM 的 context：有些候选会被 rerank、token 裁剪丢掉，两类接口最好都返回，方便定位问题

八、问题集：检索召回还是 LLM 问答用

结论：**同一套问题集同时覆盖两层，但看的校验点不一样；检索召回是“因”，LLM 问答输出是“果”**。问题集输入都是同一个 question，但看两组输出：接口返回的 context（source_documents）评价检索召回质量；接口返回的 answer 评价 LLM 生成/业务问答质量。

逻辑：用户提问 → 检索模块输出 context 切片集合（召回结果）→ 把 context 丢给 LLM → LLM 输出 answer。如果 context 本身就错，LLM 再厉害 answer 也不可能正确；如果 context 正确完整但 answer 还错，问题出在 LLM/Prompt、rerank、上下文裁剪。

1、同一个问题，两套校验预期

第一层：校验检索召回（看 context/source_documents）

关注点：召回的切片对不对，和大模型无关。校验项：预期召回哪些文档/chunk；预期不召回哪些文档/chunk；相似度分数是否合理；元数据是否正确（芯片型号、版本、时间戳）。

第二层：校验 LLM 业务问答（看 answer 输出）

前提：context 已拿到正确切片。校验项：answer 答案要点是否来源于 context；是否幻觉编造知识库以外信息；是否聚合多段 context 信息；溯源引用展示、话术格式、冲突信息处理、多轮表现。

2、3 种典型现象（定位 bug 根因）

1. context 正确，answer 错误：检索召回没问题；问题在 prompt、rerank、LLM 推理、token 截断丢了部分 context
2. context 错误（缺/无关），answer 错误：根因是检索召回失败；不要把 bug 归给大模型，优先修复检索、解析、切片
3. context 错误，但 answer 居然蒙对了：高危！大模型使用自身内部知识回答，不是来自知识库 context，属于隐藏幻觉 bug，一定要抓出来。不能只看 answer 回答正确就认为用例通过，必须同时核对 context

3、问题集什么时候侧重检索、什么时候侧重 LLM

- 新知识库刚上线、文档解析切片检索还不稳定阶段：问题集重点观测 context，优先把召回质量打稳

- 检索模块基本稳定后：同时校验 context + answer，做完整业务效果验证，回归测试全套跑
- 专项测试：检索专项只看 context 不关心 answer；LLM 问答/幻觉专项必须结合 context，区分幻觉来源（是召回不到，还是拿到正确上下文依然瞎编）

4、问题集表格字段要体现两层校验

用例ID	问题	问题类型	预期召回 context（文档/chunk）	预期 answer 要点
H-001	Hi3516 V200 VI 最大分辨率	精准正向	只召回 Hi3516V200 手册 chunk，不出现其他芯片	输出对应分辨率数值

很多人只写预期 answer 不写预期召回 context。后果：answer 碰巧对的时候，发现不了检索层面隐藏缺陷（蒙对的幻觉场景）。

5、容易踩坑的误区

- 误区 1：问题集就是用来测大模型回答好不好。错。问题集是整套 RAG 系统的输入，只看 answer 会漏掉大量底层缺陷
- 误区 2：answer 回答正确 = 用例 pass。错！必须核对 context 来源，防止大模型靠自己记忆蒙答案
- 误区 3：召回 context 正确、answer 不对，提交缺陷给检索模块。根因定位错，bug 提错模块

6、面试简短记忆版

> 问题集是整套 RAG 系统的输入，并非专属于检索或者 LLM。同一条问题，我们观察两个输出：context 用来验证检索召回模块；answer 用来验证 LLM 业务问答模块。如果 context 本身召回错误，answer 大概率错误，缺陷根因落在检索链路（解析、切片、向量检索、元数据过滤）；如果 context 是正确的，但 answer 输出错误，则问题在 Prompt、rerank、LLM 侧。尤其要警惕一种风险：context 召回不对，但 answer 碰巧输出正确答案，这是模型利用自身知识产生的隐性幻觉，只看 answer 无法发现该缺陷，所以测试问题集必须同时设计 context 预期和 answer 预期。

九、兼容、稳定、性能测试

知识库完整包含这三类测试，但与普通 Web 接口侧重点不一样，很多测试点是 RAG 特有的。

1、兼容性测试

文件格式兼容（最核心）

支持格式：pdf、docx、doc、txt、md、ppt、pptx、excel；边界：加密 pdf、扫描件 PDF（图片版）、损坏文件、超大单文件、中文/特殊符号、繁体、混合中英文、带表格/图片/页眉页脚的文档。校验：能否上传、解析是否丢表格、乱码、图片丢失、切片是否异常。很多坑：老版 doc 解析失败、扫描 PDF 识别为空、复杂表格解析错乱。

前端页面兼容

浏览器 Chrome、Edge；不同分辨率；如有移动端也测。知识库列表、文件上传、问答对话、溯源引用片段展示、分页。

API 调用兼容

不同参数组合、不同编码；第三方业务系统调用知识库接口；多租户场景下不同租户调用。入参超长 query、特殊字符 query，接口不能直接崩溃。

模型版本兼容

切换不同 LLM 模型、不同向量模型版本，知识库原有向量库数据是否正常，检索、问答结果是否可用，不出现报错。

2、稳定性测试

业务稳定性

- 大批量文档导入：持续上传大量文件，观察解析任务队列，会不会任务卡死、状态一直“解析中”、任务丢失、重复切片
- 混合并发：一边上传解析文档，一边发起问答检索请求
- 异常中断：上传中途断网；解析过程重启服务；中途杀掉向量服务；数据库重启。校验任务状态正确，不产生大量脏切片、脏向量，不无限重试
- 长时间压测（耐久）：持续几小时反复问答、导入，监控内存、CPU，是否内存泄漏，接口响应逐步变慢
- 脏数据容错：存在解析失败文档、损坏向量，不能导致整个知识库问答直接不可用

数据层面稳定性

- 删除文档：对应的切片、向量是否清理干净；不能还能检索出已经删除的内容（经典 bug）
- 更新文档：同名文件覆盖上传，旧向量是否清理，检索优先返回新内容
- 多租户隔离稳定性：A 租户文档 B 租户检索不到；租户删除，向量、切片全部清理

3、性能测试

知识库性能分两大链路：**文档导入链路 + 问答检索链路**，两者都要压，很多人只压问答忽略上传解析性能。

文档导入链路性能

流程：上传→解析→切片→向量化→入库向量库。测试点：单文件不同大小解析耗时；N 个文档并发导入看队列吞吐量；向量化耗时。观测指标：解析成功率、平均解析耗时、最大排队时长；任务不超时；服务 CPU、内存、向量库负载。

问答检索链路性能（用户侧）

链路：用户提问 → query 向量化 → 向量库召回切片（context）→ 重排 → 传给 LLM → 返回答案。压测场景：普通并发问答（区分简单/复杂长问题）；知识库数据量级（小库几百文档、中大库上万文档）。观测指标：接口 TTFB、完整响应时间；召回耗时（向量检索耗时）；LLM 生成耗时；QPS；错误率；超时率；资源（API 服务、向量数据库、重排服务、LLM 网关 CPU/内存）。

重要：知识库不要只看接口成功，性能下降同时会带来业务问题：检索召回变慢、召回 top 文档不对、问答质量变差。

性能边界场景

- 超长用户 query
- 需要召回大量切片（top_k 设置很大），看响应、内存是否异常
- 向量库高负载下降级策略：返回友好报错，而不是服务雪崩

4、三类测试容易踩坑总结

- 兼容：不要只测正常 PDF，扫描件、老格式文档是重灾区
- 稳定：重点测“文档增删改”，向量脏数据是 RAG 特有 bug，普通 Web 系统没有；并发【导入+问答】混合场景
- 性能：必须拆成「导入解析链路」和「问答检索链路」分别压；不同知识库数据规模下都要跑性能

补充：除了兼容、稳定、性能，知识库核心还要做功能测试（上传解析切片召回溯源）、问答效果测试（问题集评测）、安全测试（权限、越权）。

十、全对话总结

本次围绕企业知识库（媒资/银行场景、海思芯片研发知识库）开展 RAG 系统测试相关讨论，汇总所有议题：

1、基础对象：知识库是什么，场景差异

- 普通文档知识库 vs 媒资知识库：媒资知识库除文本外还包含音视频、图片等素材，需额外处理媒资转文本、字幕提取等能力
- 行业场景：银行知识库（强合规、敏感信息、业务话术、监管文档）；海思芯片研发知识库（技术手册、芯片文档、研发内部资料）

2、核心模块测试范围

- 文件上传、文档解析、文本切片、向量化：需要测试底层逻辑，不只测上传结果。解析：特殊格式、乱码、表格/图片内文字、分页、页眉页脚是否正确提取；切片：切片大小、重叠窗口、是否切断语义、标题与正文关联；向量化：切片是否成功入库向量库、重复文档向量策略
- 检索召回：独立测试环节，评估召回相关度、召回数量、是否召回无关文档
- LLM 问答（业务问答）：基于召回上下文生成答案，和检索召回是两个独立评测环节
- 溯源上下文 context：溯源方法是查看大模型拿到的原始上下文；获取方式为调用后端接口看返回的 context 字段，判断答案来源

3、测试问题集

- 问题集用途：同时用于检索召回测试 + LLM 业务问答测试，两套观测指标不一样。检索召回看召回文档/切片是否正确；LLM 问答看最终回答是否准确、是否幻觉、是否引用原文
- 银行项目的问题集准备：有明确编制依据，按业务分类、合规类、边界问题、负向问题构造样例

4、专项测试：兼容、稳定性、性能测试

- 兼容性：文件格式兼容、浏览器/客户端兼容、不同版本文档兼容、多租户隔离兼容
- 稳定性：长时间持续上传文档、持续问答、并发下服务稳定性，异常恢复（断网、服务重启、向量库异常）
- 性能：文档批量上传耗时、解析切片耗时、向量入库耗时、问答接口响应时间、并发问答、海量知识库下检索耗时

5、其他配套测试

- 权限测试：不同角色能否访问对应知识库/文档
- 安全测试：敏感信息泄露、提示词注入
- 评测指标：召回率、准确率、幻觉率、溯源正确性
- 缺陷分级：支持按 P0/P1/P2/P3 分级管理

6、核心疑问回顾

- Q：切片、向量化业务层看不到，是否需要测？A：需要，这是 RAG 底层核心，业务层仅能看到上传成功，但解析错误、切片切坏、向量入库失败会直接导致问答错误
- Q：问题集是给检索召回用还是 LLM 问答？A：都要用，同一套问题集可以分别观测召回结果、LLM 回答结果
- Q：溯源上下文怎么看？A：调用接口，查看接口返回的 context，就是传给大模型的参考片段，用来核对答案来源

（注：部分内容由豆包工作 AI 生成）